

BABEȘ BOLYAI UNIVERSITY, CLUJ NAPOCA, ROMÂNIA  
FACULTY OF MATHEMATICS AND COMPUTER SCIENCE

# Predictive Mental Health Monitoring System

– MIRPR report –

## **Membrii echipei**

Kentsch Karina, informatica romana, 234, karina.kentsch@stud.ubbcluj.ro

Irimies Vasile, informatica romana, 234, vasile.irimies@stud.ubbcluj.ro

Lechea Daniel, informatica romana, 234, daniel.lechea@stud.ubbcluj.ro

# Contents

<b>1</b>	<b>Introducere</b>	<b>1</b>
1.1	Ideea de baza . . . . .	1
1.2	Motivatie . . . . .	1
<b>2</b>	<b>Problema stiintifica abordata</b>	<b>3</b>
2.1	Descrierea problemei . . . . .	3
<b>3</b>	<b>Metode existente de rezolvare a problemei</b>	<b>5</b>
3.1	Articolul 1 . . . . .	5
3.2	Articolul 2 . . . . .	6
3.3	Articolul 3 . . . . .	6
3.4	Articolul 4 . . . . .	7
3.5	Articolul 5 . . . . .	8
3.6	Articolul 6 . . . . .	8
3.7	Articolul 7 . . . . .	9
3.8	Sinteza articolelor . . . . .	11
<b>4</b>	<b>Mind Map</b>	<b>12</b>
<b>5</b>	<b>Metode efectiv folosite pentru rezolvarea problemei</b>	<b>13</b>
5.1	Prelucrarea datelor de intrare . . . . .	13
5.2	Etapa de uniformizare a datelor . . . . .	13
5.3	Selectarea datelor relevante . . . . .	14
5.4	Normalizare si vizualizare . . . . .	14
5.5	Impartirea datelor in seturi de antrenament si test . . . . .	14
5.6	Construirea modelului inteligent . . . . .	14
5.6.1	Abordare cu LSTM . . . . .	14
5.6.2	Abordare cu RNN . . . . .	15
5.7	Fuzionarea rezultatelor si utilizarea unui ANN . . . . .	15
5.8	Antrenarea modelului si evaluarea performantei . . . . .	15
<b>6</b>	<b>Rezultate experimentale obtinute</b>	<b>16</b>
6.1	Rezultate obtinute . . . . .	16
6.1.1	Reprezentarea evolutiei functiei de loss si a matricii de confuzie . . . . .	17
6.1.1.1	Cazul de rulare 1 . . . . .	17
6.1.1.2	Cazul de rulare 2 . . . . .	18
6.1.1.3	Cazul de rulare 3 . . . . .	18
6.1.1.4	Cazul de rulare 4 . . . . .	19
6.2	Comparare cu SOTA . . . . .	19
6.2.1	Acuratete . . . . .	19

---

6.2.2	Precizie si Recall . . . . .	20
6.2.3	Complexitatea modelului . . . . .	20
6.2.4	Date de intrare . . . . .	20
<b>7</b>	<b>Concluzii si posibile imbunatatiri</b>	<b>21</b>

# Chapter 1

## Introducere

### 1.1 Ideea de baza

Sistemul de monitorizare a sanatatii mintale reprezinta o solutie inovatoare ce foloseste dispozitive portabile, pentru a urmari indicatori esentiali de sanatate si a oferi informatii in timp real despre starea psihica a utilizatorului.

Prin integrarea algoritmilor avansati de machine learning si a tehnologiilor moderne de analiza a datelor, sistemul este conceput sa anticipeze si sa previna actiunile suicidare.

Scopul sau este de a furniza interventii personalizate si sprijin la momentul oportun, prin monitorizarea continua si analiza inteligenta a datelor de sanatate colectate, contribuind astfel la reducerea riscurilor si imbunatatirea starii de bine a utilizatorilor.

### 1.2 Motivatie

Utilizarea unui algoritm inteligent pentru monitorizarea sanatatii mintale si prevenirea actiunilor suicidare este esentiala datorita naturii complexe si dinamice a factorilor care influenteaza starea psihica a unei persoane.

Factorii legati de sanatatea mintala variaza in timp si sunt influentati de o multitudine de date, toate putand fi monitorizate prin dispozitive portabile. Aceste informatii sunt greu de interpretat manual in timp real si intr-o maniera eficienta.

Un algoritm inteligent este capabil sa analizeze aceste date intr-un mod continuu si complex, identificand modele care ar putea semnala un risc crescut de deteriorare a sanatatii mintale.

Prin utilizarea tehnicilor de invatare automata, algoritmul poate invata din datele colectate, devenind din ce in ce mai precis in predictiile sale, adaptandu-se la particularitatile fiecarui utilizator.

Astfel, algoritmul ofera o monitorizare continua personalizata, dar si poate interveni la momentul potrivit prin generarea de alerte si recomandari pentru utilizator prevenind astfel evolutia negativa a starii mintale.

## Chapter 2

# Problema stiintifica abordata

### 2.1 Descrierea problemei

Problema stiintifica centrala abordata consta in identificarea timpurie si prevenirea starilor psihice critice, prin monitorizarea continua a starii mentale a unei persoane folosind date colectate de la dispozitive purtabile.

Provocarea consta in dezvoltarea unui model care sa fie capabil sa analizeze in mod eficient si precis aceste date, sa detecteze tipare legate de sanatatea mintala.

Pentru a aborda aceste aspecte, problema stiintifica presupune:

- Colectarea si integrarea unor volume mari de date complexe provenite de la dispozitive purtabile
- Dezvoltarea unui algoritm inteligent capabil sa extraga informatii relevante din aceste date, identificand tipare care indica un risc de deteriorare a sanatatii mintale
- Utilizarea metodelor de machine learning pentru a face predictii

În contextul acesta, scopul principal este de a clasifica starea mentală a unei persoane în patru categorii (baseline, stress, amusement, meditation) pe baza datelor colectate de la un dispozitiv.

În acest caz, modelul trebuie să identifice în ce stare se afla persoana ceea ce face ca problema să fie una de clasificare.




Figure 2.1: Schema rezolvării problemei

După ce modelul a fost antrenat, vom evalua calitatea acestuia utilizând următoarele măsuri:

1. **Acuratetea:** Reprezintă proporția predicțiilor corecte față de numărul total de predicții efectuate. Aceasta este o măsurătoare generală care indică cât de bine reușește modelul să identifice corect starea unei persoane. Deși acuratetea poate fi un indicator util, în contextul acestui model, este important să acordăm o atenție deosebită cazurilor de risc ridicat de suicid, pentru a ne asigura că acestea sunt corect identificate.
2. **Precizia:** Măsoară proporția predicțiilor corecte de "risc" dintre toate cazurile în care modelul a prezis "risc". Cu alte cuvinte, aceasta arată cât de multe dintre persoanele pentru care modelul a prezis că se află într-o stare de risc sunt, într-adevăr, în risc. Precizia este esențială pentru a minimiza alarmele false, asigurându-se că intervențiile sunt realizate doar în cazurile cu adevărat necesare.
3. **Recall:** Măsoară proporția cazurilor de "risc" reale care au fost corect identificate de model. Aceasta indică în ce măsură modelul este capabil să detecteze toate persoanele aflate într-o stare de risc de suicid. Deși un recall ridicat este esențial pentru a nu pierde nicio persoană aflată într-o stare de risc, este important de menționat că un recall ridicat însoțit de o precizie scăzută poate semnala că modelul generează multe alarme false.

## Chapter 3

# Metode existente de rezolvare a problemei

### 3.1 Articolul 1

Numele articolului: Evaluation of an Integrated System of Wearable Physiological Sensors for Stress [2]

Date de intrare:

- electroencefalograma - EEG
- electrodiagrama - ECG
- activitate electrodermala - EDA
- nivelul de oxigen - SpO2

Date de iesire:

- clasificare - baseline/stress

Algoritmul de ML utilizat:

- masina cu suport vectorial (SVM)
- acuratete: 86%

Detalii:

- dataset propriu, 15 participanti dintre care doar pentru 12 au fost date valide
- performanta calculata pentru validation set



### 3.2 Articolul 2

Numele articolului: Emotion Recognition based on fusion of multimodal physiological signals using LSTM and GRU [4]

LSTM = un tip de retea neuronală recurentă (RNN) menită să atenueze problema gradientului de dispariție întâlnită în mod obișnuit de RNN-urile tradiționale.

GRU = memorie pe termen scurt (LSTM) cu un mecanism de intrare pentru a introduce sau uita anumite caracteristici, dar nu are un vector de context sau o poartă de ieșire, rezultând mai puțini parametri decât LSTM.

Date de intrare:

- electrodiagrama - ECG
- electroencefalograma - EEG
- respirația
- temperatura

Date de ieșire:

- clasificare - trist/neutru/fericit

Algoritmul de ML utilizat:

- multi modal fusion network
- GRU (Gated Recurrent Unit) => acuratețe 73%
- LSTM (Long Short-Term Memory) => acuratețe: 74%

### 3.3 Articolul 3

Numele articolului: Stress Detection Using Wearable Physiological Sensors [5]

Date de intrare:

- activitate electrodermală - EDA
- blood volume pulse - BVP
- variabilitatea ritmului cardiac - HRV

- pulse plethysmograph - PPG

Date de iesire:

- clasificare - cu stres/fara stres

Algoritmul de ML utilizat:

- masina cu suport vectorial (SVM)

Detalii:

- dataset propriu
- 5 participanti
- pentru fiecare participant  $D = \{D1, D2, D3, D4, D5\}$ , dimensiunea seturilor de date  $D_k$ , adica numarul de vectori de caracteristici, a fost:  $|D1|=11620$ ,  $|D2|=13450$ ,  $|D3|=13740$ ,  $|D4|=13740$ ,  $|D5|=13000$
- nu se precizeaza daca dataset-ul poate fi accesat
- nu se precizeaza pe ce a fost obtinuta performanta

### 3.4 Articolul 4

Numele articolului: Attention based hybrid deep learning model for wearable based stress recognition [6]

Date de intrare:

- activitate electrodermala - EDA
- electrodiagrama - ECG
- electromyography - EMG
- respiratia
- temperatura

Date de iesire:

- clasificare - stress/baseline/amusement

Algoritmul de ML utilizat:

- model hibrid de invatare profunda bazat pe atentie, format din CNN si LSTM

Detalii:

- dataset WESAD si performanta accuracy pana la 92.7%
- performanta calculata pentru datele de validare (10% din dataset)
- batch size is set to 256 si modelul e antrenat cu 50 de epoci

### 3.5 Articolul 5

Numele articolului: A hybrid transposed attention based deep learning model for wearable and explainable stress recognition [7]

Date de intrare:

- WESAD dataset
- input multimodal

Date de iesire:

- clasificare - stress/baseline/amusement

Algoritmul de ML utilizat:

- model hibrid de invatare profunda bazat pe atentie, format din CNN transpus si LSTM
- acuratete: 93%

Detalii:

- performanta calculata pentru datele de validare (20% din dataset)

### 3.6 Articolul 6

Numele articolului: A machine learning approach to determine resilience utilizing wearable device data: analysis of an observational cohort [3]

Date de intrare:

- variatia ritmului cardiac - HRV

- ritmul cardiac in momentul repausului - RHR
- varsta
- sex
- body mass index - BMI

Date de iesire:

- clasificare - high/low

Algoritmul de ML utilizat:

- gradient-boosting machines (GBM) si extreme gradient-boosting models

Detalii:

- warrior watch study dataset, de la 7 spitale, 329 de participanti, nu este disponibil pe internet, dar este mentionat "researchers interested in gaining access to the data can contact the corresponding author"
- 85% accuracy train, 60% accuracy test

### 3.7 Articolul 7

Numele articolului: Human stress classification during public speaking using physiological signals [\[1\]](#)

Date de intrare:

- electroencefalograma - EEG
- galvanic skin response - GSR
- photoplethysmograph - PPG

Date de iesire:

- clasificare stresului in doua clase

Algoritmul de ML utilizat:

- masina cu suport vectorial (SVM)
- clasificator cu functie de baza radiala

- acuratete: 96%

Detalii:

- dataset propriu, 40 de participant
- foloseste leave-one-out cross-validation => performanta calculata pentru validation
- nu se precizeaza numarul de exemple
- nu se precizeaza nimic de accesul la dataset

### 3.8 Sinteza articolelor

Articol	Date de intrare	Date de iesire	Algoritm utilizat
Evaluation of an Integrated System of Wearable Physiological Sensors for Stress	other	baseline/ stress	SVM - acuratete: 86%
Emotion Recognition based on fusion of multimodal physiological signals using LSTM and GRU	temperatura, other	trist/ neutru/ fericit	GRU(73%) LSTM(74%)
Stress Detection Using Wearable Physiological Sensors	BVP, EDA, other	cu stres/fara stres	SVM
Attention based hybrid deep learning model for wearable based stress recognition	temperatura, EDA, other	stress/ baseline/ amusement	CNN+LSTM
A hybrid transposed attention based deep learning model for wearable and explainable stress recognition	temperatura, BVP, ACC, EDA, other	stress/ baseline/ amusement	CNN+LSTM(93%)
A machine learning approach to determine resilience utilizing wearable device data: analysis of an observational cohort	other	high/low	GBM
Human stress classification during public speaking using physiological signals	other	clasificarea stresului in 2 clase	SVM (96%)

## Chapter 4

# Mind Map

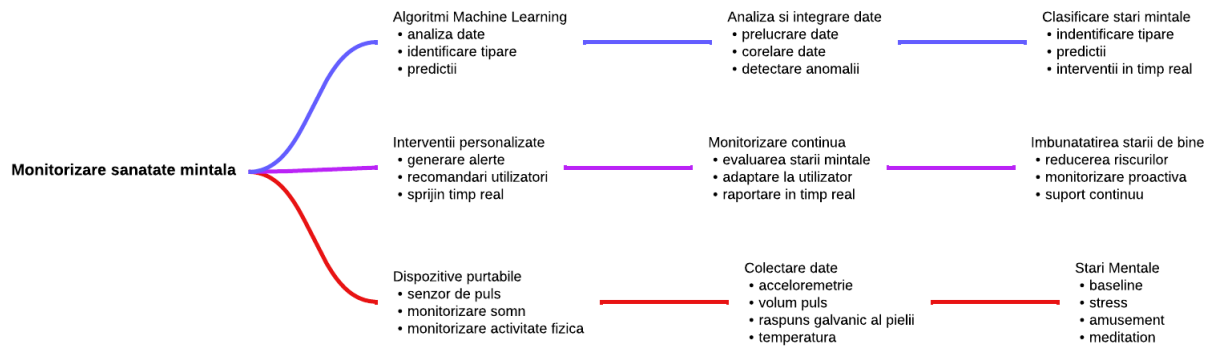


Figure 4.1: Mind Map

## Chapter 5

# Metode efectiv folosite pentru rezolvarea problemei

### 5.1 Prelucrarea datelor de intrare

Procesul incepe cu prelucrarea datelor de intrare, care sunt furnizate in format ".pkl" si constau in masuratori fiziologice de la un ceas inteligent, inclusiv: ACC(accelerometrie), BVP(volum puls), EDA(raspuns galvanic al pielii) si TEMP(temperatura).

Aceste date au fost preluate dintr-un dataset public numit WESAD (Wearable Stress and Affect Detection) din care am preluat doar masuratorile preluate de la incheietura relevante pentru problema abordata.

Fiecare dintre aceste tipuri de date reflecta un aspect diferit al raspunsului corpului la diferiti stimuli si poate oferi indicii valoroase despre starea psihologica si fizica a utilizatorului.

### 5.2 Etapa de uniformizare a datelor

Pentru a ne asigura ca toate datele pot fi analizate impreuna, aplicam un proces de downsampling, deoarece fiecare tip de masuratoare este preluata la o frecventa diferita.

In urma procesului de downsampling avem 24316 inregistrari pentru un pacient, iar in urma filtrarii ramanem cu 7036.

Prin downsampling, reducem datele la o frecventa comuna si obtinem un set de date cu o dimensiune unitara, ceea ce permite o comparatie si o analiza mai eficienta intre diferitele masuratori.



### 5.3 Selectarea datelor relevante

Dupa uniformizare, filtram datele pentru a pastra doar acele inregistrari etichetate cu "baseline", "stress", "amusement", "meditation". Etichetele "baseline" indica starea obsinuita a utilizatorului, etichetele "stress" reflecta momente in care utilizatorului a experimentat un nivel crescut de stres, etichetele "amusement" indica faptul ca pacientul este entuziasmat, iar etichetele "meditation" indica starea generala de bine a utilizatorilor.

Aceasta selectie ne permite sa ne concentram doar pe datele critice pentru model, cele care pot evidentia variatii relevante in functie de starile psihologice ale utilizatorului.

### 5.4 Normalizare si vizualizare

Inainte de a trece la modelare, normalizam datele utilizand tehnica de scalare Min-Max, ceea ce ne permite sa aliniam valorile tuturor variabilelor intr-un interval comun, de obicei intre 0 si 1.

Normalizarea elimina variatiile extreme si faciliteaza invatarea modelului. Dupa normalizare, vizualizam datele pentru a verifica acuratetea prelucrarii si pentru a observa tiparele initiale ale datelor.

### 5.5 Impartirea datelor in seturi de antrenament si test

In etapa urmatoare, impartim setul de date prelucrat in doua subseturi: 70% din date vor fi utilizate pentru antrenarea modelului, iar 30% vor fi folosite pentru testare.

Aceasta impartire asigura o baza solida pentru antrenare si permite verificarea performantei modelului pe un set de date nou, pentru a evita suprainvatarea.

### 5.6 Construirea modelului inteligent

#### 5.6.1 Abordare cu LSTM

Modelul se bazeaza pe Long Short-Term Memory (LSTM), un tip special de retea neuronală recurentă (RNN) potrivit pentru analiza secventelor de date.

LSTM este capabil sa retina informatii pe termen lung si scurt, facandu-l ideal pentru date fiziologice secventiale, cum ar fi cele colectate de la senzorii unui ceas inteligent.

Vom construi cate un model LSTM de tip many-to-one pentru fiecare tip de date de intrare (ACC, TEMP, BVP, EDA). Acest model prelucreaza secventele de date individual si capteaza evolutia fiecarui tip de semnal in timp.




Figure 5.1: Arhitectura LSTM

### 5.6.2 Abordare cu RNN

O alta varianta este cea in care modelul se bazeaza pe Retele Neuronale Recurente simple (RNN), potrivite pentru analiza secventelor de date. RNN-urile sunt capabile sa capteze corelatiile temporale din datele fiziologice secventiale, cum sunt cele colectate de la senzorii unui ceas inteligent, dar pastreaza mai putine informatii pe termen lung decat LSTM.

Vom contrui un model RNN many-to-one pentru fiecare tip de date de intrare, permitandu-i sa prelucreze individual secventele de date si sa capteze variatiile fiecarui tip de semnal pe o perioada limitata de timp.

## 5.7 Fuzionarea rezultatelor si utilizarea unui ANN

Iesirile generate de fiecare LSTM sunt apoi fuzionate intr-un vector comun, care este introdus intr-o Retea Neuronala Artificiala (ANN).

ANN va procesa aceste date agregate si va genera o clasificare multi-clasa: baseline, stress, amusement, meditation.

Aceasta clasificare indica starea mentala a utilizatorului, pe baza tiparelor si variatiilor din datele fiziologice.

## 5.8 Antrenarea modelului si evaluarea performantei

Pentru antrenarea modelului, folosim algoritmul de optimizare Adam, cunoscut pentru eficienta sa in actualizarea ponderilor si functia de loss Categorical Cross Entropy, care ajuta modelul sa minimizeze erorile de predictie.

La final, evaluam calitatea modelului masurand acuratetea sa pe setul de testare. Acest pas ne ofera o masura a performantei modelului in evaluarea starii mentale a utilizatorilor pe baza datelor colectate.

## Chapter 6

# Rezultate experimentale obtinute

### 6.1 Rezultate obtinute

Descrierea modelului folosit	Date de intrare	Performanta
6 LSTM + ANN lungimea secventei retinute: 5 numarul de neuroni din startul ascuns din ANN: 5 Nr. epoci: 3	S2.pkl	<b>Accuracy:</b> 79% <b>Precision:</b> 54% <b>Recall:</b> 81%
Cate un Simple RNN pentru fiecare feature + ANN lungimea secventei retinute: 15 numarul de neuroni din startul ascuns din ANN: 15 Nr. epoci: 3	S2.pkl	<b>Accuracy:</b> 84% <b>Precision:</b> 75% <b>Recall:</b> 80%
6 LSTM + ANN lungimea secventei retinute: 20 Numarul de neuroni din stratul ascuns din ANN: 60 Nr. epoci: 10	Toti subiectii: S2 -> S17	<b>Accuracy:</b> 52% <b>Precision:</b> 42% <b>Recall:</b> 35%
Cate un LSTM pentru fiecare feature + ANN lungimea secventei retinute: 15 Numarul de neuroni din stratul ascuns din ANN: 30 Nr. epoci: 5	Toti subiectii: S2 -> S17	<b>Accuracy:</b> 46% <b>Precision:</b> 48% <b>Recall:</b> 46%

Descrierea modelului folosit	Date de intrare	Performanta
Cate un LSTM pentru fiecare feature+ ANN lungimea secventei retinute: 15 Numarul de neuroni din stratul ascuns din ANN: 70 Nr. epoci: 15	Toti subiectii: S2 -> S17	<b>Accuracy:</b> 89% <b>Precision:</b> 93% <b>Recall:</b> 91%
Cate un LSTM pentru fiecare feature + ANN lungimea secventei retinute: 10 Numarul de neuroni din stratul ascuns din ANN: 50 Nr. epoci: 15	Toti subiectii: S2 -> S17	<b>Accuracy:</b> 89% <b>Precision:</b> 94% <b>Recall:</b> 93%
Cate un RNN pentru fiecare feature + ANN lungimea secventei retinute: 10 Numarul de neuroni din stratul ascuns din ANN: 50 Nr. epoci: 15	Toti subiectii: S2 -> S17	<b>Accuracy:</b> 29% <b>Precision:</b> 27% <b>Recall:</b> 23%

### 6.1.1 Reprezentarea evolutiei functiei de loss si a matricii de confuzie


#### 6.1.1.1 Cazul de rulare 1

Cate un LSTM pentru fiecare input + ANN


Lungimea secventei retinute: 15

Numarul de neuroni din statul ascuns din ANN: 30

Numarul de epoci: 5



(a) Matrice de confuzie



(b) Evolutia functiei de loss

Figure 6.1: Evolutia procesului de antrenare


### 6.1.1.2 Cazul de rulare 2

Cate un LSTM pentru fiecare input + ANN


Lungimea secventei retinute: 15

Numarul de neuroni din statul ascuns din ANN: 70

Numarul de epoci: 15



(a) Matrice de confuzie



(b) Evolutia functiei de loss

Figure 6.2: Evolutia procesului de antrenare


### 6.1.1.3 Cazul de rulare 3

Cate un RNN pentru fiecare input + ANN


Lungimea secventei retinute: 10

Numarul de neuroni din statul ascuns din ANN: 50

Numarul de epoci: 15



(a) Matrice de confuzie



(b) Evolutia functiei de loss

Figure 6.3: Evolutia procesului de antrenare


#### 6.1.1.4 Cazul de rulare 4

Cate un RNN pentru fiecare input + ANN

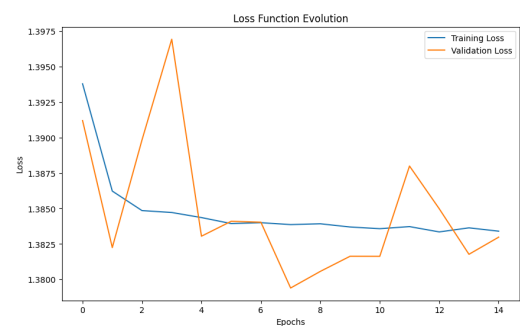
Lungimea secventei retinute: 10

Numarul de neuroni din statul ascuns din ANN: 50

Numarul de epoci: 15



(a) Matrice de confuzie



(b) Evolutia functiei de loss

Figure 6.4: Evolutia procesului de antrenare

## 6.2 Comparare cu SOTA

Descrierea modelului folosit	Date de intrare	Performanta
Model hibrid de invatare profunda bazat pe atentie format din CNN si LSTM	WESAD	<b>Accuracy: 93%</b>
Cate un LSTM pentru fiecare feature + ANN lungimea secventei retinute: 10 Numarul de neuroni din stratul ascuns din ANN: 50 Nr. epoci: 15	Toti subiectii: S2 -> S17	<b>Overall Accuracy: 89%</b> <b>Precision: 94%</b> <b>Recall: 93%</b>

### 6.2.1 Acuratete

- Modelul hibrid de invatare profunda bazat pe atentie (CNN + LSTM) a obtinut o acuratete de 93%
- Modelul antrenat in cadrul acestui proiect (6 LSTM + ANN) are acuratetea de 89%

- Diferenta de acuratete poate fi atribuita utilizarii arhitecturii hibride care combina avantajele CNN si LSTM, permitand modelului sa capteze atat caracteristicile spatiale cat si cele temporale ale datelor

### 6.2.2 Precizie si Recall

- Modelul antrenat in acest proiect a obtinut o precizie de 94% si un recall de 93%, ceea ce indica o mai mare dificultate a acestuia de a identifica corect toate instantele pozitive si de a minimiza falsurile pozitive fata de SOTA
- Modelul hibrid nu a raportat valori pentru precizie si recall, dar acuratetea sa ridicata sugereaza o performanta generala mai buna

### 6.2.3 Complexitatea modelului

- Modelul hibrid utilizeaza o combinatie de CNN si LSTM, ceea ce poate adauga complexitate si necesita mai multe resurse computationale
- Modelul antrenat in acest proiect utilizeaza o arhitectura LSTM + ANN care este mai simpla, dar poate fi optimizata in continuare pentru a imbunatati performanta

### 6.2.4 Date de intrare

- Modelul hibrid a fost antrenat pe setul de date WESAD, care e un set de date bine cunoscut si utilizat in cercetarea privind recunoasterea emotiilor si stresului.
- Modelul antrenat in acest proiect a fost antrenat pe datele de la mai multi subiecti care au attribute regasite in WESAD

## Chapter 7

### Concluzii si posibile imbunatatiri



# Bibliography

- [1] Aamir Arsalan and Muhammad Majid. Human stress classification during public speaking using physiological signals. 2021.
- [2] Stefano Betti, Raffaele Molino Lova, Erika Rovini, Giorgia Acerbi, Luca Santarelli, Manuela Caviati, Silvia Del Ry, and Filippo Cavallo. Evaluation of an integrated system of wearable physiological sensors for stress monitoring in working environments by using biological markers. pages 1748–1758, 2017.
- [3] Robert P Hirten, Maria Suprun, Matteo Danieletto, Micol Zweig, Eddy Golden, Renata Pyzik, Sparshdeep Kaur, Drew Helmus, Anthony Biello, Kyle Landell, Jovita Rodrigues, Erwin P Bottinger, Laurie Keefer, Dennis Charney, Girish N Nadkarni, Mayte Suarez-Farinas, and Zahi A Fayad. A machine learning approach to determine resilience utilizing wearable device data: analysis of an observational cohort. 2023.
- [4] N Priyadarshini and J Aravinth. Emotion recognition based on fusion of multimodal physiological signals using lstm and gru. 2023.
- [5] Virginia Sandulescu, Sally Andrews, David Ellis, Nicola Bellotto, and Oscar MartÁñez Mozos. Stress detection using wearable physiological sensors. pages 526–532, 2015.
- [6] Ritu Tanwar, Orchid Chetia Phukan, Ghanapriya Singh, Pankaj Kumar Pal, and Sanju Tiwari. Attention based hybrid deep learning model for wearable based stress recognition. 2023.
- [7] Ritu Tanwar, Ghanapriya Singh, and Pankaj Kumar Pal. A hybrid transposed attention based deep learning model for wearable and explainable stress recognition. 2024.